

Combination of Deep Features and KNN Algorithm for Classification of Leaf-Based Plant Species

Yaprak Tabanlı Bitki Türlerinin Sınıflandırılması için Derin Özellikler ve KNN Algoritmasının Kombinasyonu

Muammer TÜRKOĞLU
Bilgisayar Mühendisliği, Bingöl Üniversitesi
Bingöl, Türkiye
mturkoglu@bingol.edu.tr

Davut HANBAY
Bilgisayar Mühendisliği, İnönü Üniversitesi
Malatya, Türkiye
davut.hanbay@inonu.edu.tr

Özetçe—Son zamanlarda, birçok görüntü işleme problemlerinin çözümünde kullanılan Evrişimsel Sinir Ağları (ESA), tarımsal alandaki birçok problem için kullanılarak başarılı sonuçlar elde edilmiştir. Bu çalışmada, bitki türlerinin sınıflandırılması için derin mimarilerinin kombinasyonuna dayalı bir yaklaşım önerilmiştir. Önceden eğitilmiş AlexNet ve VGG16 modellerinin fc6 katmanı kullanılarak bitki yapraklarından derin özellikler çıkartılmıştır. Daha sonra, Temel Bileşen Analizi (TBA) yöntemi kullanılarak derin özelliklerin sayısının indirgenmesi hızlı bir şekilde yapılmış ve en iyi ayırt edici özellikler elde edilmiştir. Son olarak, K- En Yakın Komşu (KNN) yöntemi kullanılarak sınıflandırma performansları hesaplanmıştır. Önerilen sistemi test etmek için Flavia ve Swedish bitki yaprak veri setleri kullanılmıştır. Gerçekleştirilen deneysel sonuçlara göre, Flavia ve Swedish veri setleri için doğruluk skorları sırasıyla %99.42 ve %99.64 olarak elde edilmiştir.

Anahtar Kelimeler — Bitki Sınıflandırılması, Evrişimsel Sinir Ağları, AlexNet modeli, VGG16 modeli, KNN sınıflandırıcısı.

Abstract— Recently, Convolutional Neural Networks (CNN), which is used in the solution of many image processing problems, has been used successfully for many problems in the agricultural field. In this study, for classification of plant species is proposed an approach based on the combination of deep architectures. Deep features were extracted from the plant leaves using the fc6 layer of the previously trained AlexNet and VGG16 models. Then, the reduction of the number of deep features by using the Principal Component Analysis (PCA) method was done quickly and the best distinguishing features were obtained. Finally, the classification performances were calculated using the K-Nearest Neighbor (KNN) method. Flavia and Swedish plant leaf data sets were used to test the proposed system. According to the experimental results, the accuracy scores for Flavia and Swedish data sets was obtained as 99.42% and 99.64%, respectively.

Index Terms—Plant Classification, Convolutional Neural Networks, AlexNet model, VGG16 model, KNN classifier.

I. GİRİŞ

Bitkiler, doğa ve insanlar için önemli bir rol oynamaktadır ve sanayi, beslenme ve tıp alanlarında yaygın olarak kullanılmaktadır. Ayrıca bitkiler ekolojik dengenin sağlanmasında hayati bir öneme sahiptir. Tüm bu nedenlerden dolayı bitki türlerini tanımlamak ve çeşitliliği koruyabilmek önemlidir. Bir bitkiyi tanımlayabilmek için botanik ve ziraat alanında uzman kişilere ihtiyaç duyulmaktadır. Bu tür yöntemler zaman alıcı, karmaşık ve ayrıntılı süreçleri içermektedir. Son zamanlarda, gelişen teknoloji ile birlikte makine öğrenmesine dayalı yöntemler kullanılarak bitki türlerinin sınıflandırılması daha kolay hale gelmiştir [1-3].

Bitki türlerinin sınıflandırılması için makine öğrenmesine dayalı birçok çalışma yapılmıştır. Bu çalışmaların çoğunda geleneksel yöntemler olarak adlandırılan şekil, renk ve doku tabanlı yöntemler kullanılmıştır. Günümüzde ise üretilen yüksek hafızalı ve güçlü bilgisayarlar sayesinde derin öğrenmenin temelini oluşturan Evrişimsel Sinir Ağlara dayalı modeller geliştirilmiştir. Tablo 1’de bitki türlerinin sınıflandırılması için geleneksel ve derin algoritmalar kullanılarak gerçekleştirilen çalışmalar verilmiştir.

TABLE I. ÖNCEKİ ÇALIŞMALAR

	Referans	Yöntem	Sınıflandırıcı
Geleneksel Yöntemler	[4]	Yerel İkili Örüntüler (YİÖ)	Destek Vektör Makinesi (DVM)
	[5]	Renk ile şekil özellikleri ve Gri Seviye Eş-Oluşum Matrisleri (GSEM)	DVM
	[6]	Geometrik-Şekil özellikleri	Olasılıksal Sinir Ağı (OSA)
	[7]	Geometrik özellikleri	Yapay Sinir Ağları (YSA)
	[8]	Renk ile şekil özellikleri, GSEM ve Zernike Moment	OSA
Derin Öğrenme	[9]	AlexNet, VGGNet ve GoogleNet	ESA

	[10]	VGG16	DVM
	[11]	AlexNet ve GoogleNet	ESA

Bu çalışmada, önceden eğitilmiş ESA modelleri kullanılarak bitki görüntülerine ait derin özellikler elde edilmiştir. Bu parametreler, TBA yöntemi kullanılarak boyutu indirgenmiş ve en iyi ayırt edici özellikler elde edilmiştir. Önerilen sistemi test etmek için Flavia ve Swedish bitki yaprak veri setleri kullanılmıştır. Son olarak, sistemin performansını test etmek için KNN sınıflandırıcı kullanılmıştır. Önerilen sistemin ana katkıları şunlardır;

- Bu çalışmada, bitki türlerinin sınıflandırılması için önceden eğitilmiş farklı derin mimarilerinin öğrenilmiş ağırlıklarının kombinasyonuna dayalı bir yaklaşım önerilmiştir.
- Önerilen sistemde, TBA yöntemi kullanılarak derin mimarilerden elde edilen özellikler arasında en iyi ayırt edici parametreler seçilmiştir.
- Geleneksel yöntemlerden farklı olarak önerilen sistem, ham/işlenmemiş görüntüler kullanılarak derin özellikler elde edilmiştir ve herhangi bir ön-işlem aşaması uygulanmamıştır. Bu durum, zaman açısından önemlidir ve farklı veri setleri için kullanışlı ve uygulanabilir.
- Önerilen sistem, literatürde yapılan en son çalışmalardan daha üstün performans sağlamıştır.

Bu çalışma şu şekilde organize edilmiştir. Bölüm 2’de önerilen yöntem ile ilgili teorik altyapı ve veri seti ayrıntılı bir şekilde verilirken, Bölüm 3’te önerilen sistem detaylandırılmıştır. Son olarak Bölüm 4’te deneysel çalışmalar ve sonuçları sayısal ve görsel olarak verilmiştir. Bölüm 5’de ise sonuçlar tartışılmıştır.

II. MATERTAL VE METOTLAR

Bu çalışmada, farklı derin mimariler ile geleneksel sınıflandırıcı yönteminin kombinasyonuna dayalı bir yaklaşım önerilmiştir. Gerçekleştirilen çalışmanın teorik alt yapısını oluşturan algoritmalar ve veri seti alt başlıklarda verilmiştir.

A. Evrişimsel Sinir Ağları (ESA)

Son zamanlarda, birçok görüntü işleme problemlerinin çözümünde kullanılan Evrişimsel Sinir Ağları (ESA), Derin öğrenme kavramının temelini oluşturmaktadır. Çok katmanlı algılayıcı ağ yapısına dayalı geliştirilen ve Konvolüsyon, havuzlama, Relu gibi katmanlardan oluşan ESA, günümüzde görüntü tanıma, ses tanıma, sinyal tanıma ve daha birçok alanlarda başarılı bir şekilde uygulanmaktadır [12-13].

Bu çalışmada, Derin Evrişimsel Sinir Ağlarına dayalı ve büyük veri setleri kullanılarak geliştirilen AlexNet [14] ve VGG16 [15] modelleri kullanılmıştır. Bu modeller hakkında karakteristik bilgiler Tablo 2’de verilmiştir.

TABLE II. ALEXNET VE VGG16 MODELLERİNİN ÖZELLİKLERİ

Model	Derinlik	Boyut (MB)	Parametre (Milyon)	Katman Sayısı
AlexNet	8	227	61	25

VGG16	16	515	138	41
-------	----	-----	-----	----

AlexNet mimarisi 5 adet konvolüsyon katmanı içerirken VGG16 mimarisi 16 konvolüsyon katmanından oluşmaktadır. Bu mimariler maksimum havuzlama katmanları ve 3 tam bağlı katman içermektedir.

B. Temel Bileşenler Analizi (TBA)

Temel bileşen analizi, çok değişkenli özellikler içeren büyük boyutlu verilerin daha düzenli ve düşük boyutlara indirgenmesi için kullanılan bir yöntemdir. Bu yöntem ortalama ve kovaryans matris gibi istatistiksel formüller kullanıma dayalıdır. Bu yöntemin en büyük avantajı, verilerin ağırlıkları hesaplanmaksızın özellik indirgemesi hızlı bir şekilde yapılmasını sağlar. TBA yöntemi, bilgisayar görmesi alanının yaygın olarak kullanılan bir özellik indirgeme algoritmasıdır [16-17].

Bu çalışmada, sınıflandırma performansının yükseltilmesi ve test zamanının daha hızlı yapılabilmesi için TBA yöntemi kullanılarak özneliliklerin ağırlarını dikkate alınmaksızın özellik indirgemesi yapılmıştır. Tablo 3’te, TBA yönteminin derin özellikler üzerinden pozitif etkisi olduğu gösterilmiştir.


C. K- En Yakın Komşu (KNN)

KNN sınıflandırıcısı, makine öğrenmesi ve görüntü işleme alanlarında yaygın olarak kullanılan bir istatistiksel öğrenme algoritmasıdır. Bu yöntem, önceden oluşturulmuş bir örnek kümedeki verilere yeni gelen verinin, ona en yakın mesafedeki kümeye atanmasını içermektedir [13,18-19].


Bu çalışmada, KNN algoritması türlerinde olan Hassas-KNN (Fined-KNN) kullanılmıştır. Bunun yanı sıra, komşu sayısı için 1 ile 3, iki veri arasındaki mesafe için Öklid fonksiyonu ve mesafe önemi eşit seçilmiştir.

D. Veri Setleri

Bu çalışmada, önerilen yaklaşımı test etmek için literatürde kabul görmüş ve kamuya açık olan Flavia ve Swedish veri setleri kullanılmıştır. Flavia veri seti [20], 32 farklı bitki türüne ait toplam 1907 yaprak görüntüsünü içermektedir. Swedish veri seti [21] ise, 15 farklı bitki türüne ait toplam 1125 yaprak görüntüsünü içermektedir. Her iki veri setindeki görüntüler arka zemini beyaz ve 3 kanallı renkli görüntülerden oluşmaktadır. Bu veri setlerinin her sınıfına ait yaprak örnekleri Şekil 1’de gösterilmiştir.



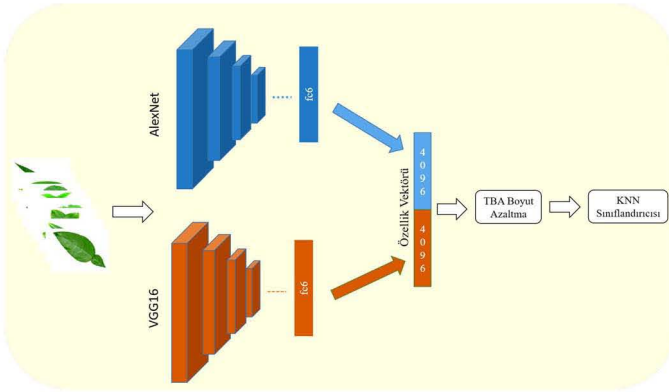
(a)



Şekil 1. Veri setleri ile ilgili yaprak örnekleri a) Flavia Veri seti b) Swedish Veri Seti

III. ÖNERİLEN DERİN-KOMBİNE YAKLAŞIMI

Bu çalışmada, Evrişimsel Sinir Ağlarına dayalı geliştirilen AlexNet ve VGG16 mimarileri kullanılmıştır. Bitki türlerinin sınıflandırılması için önceden eğitilmiş bu mimarilerinin fc6 katmanlarından öğrenilmiş ağırlıkları kullanarak derin özellikler elde edilmiştir. Her iki mimariden elde edilen 4096 özellikler birleştirilmiştir. Daha sonra, TBA yöntemi kullanılarak elde edilen derin özelliklerden ayırt edici parametreler seçilmiştir. Son olarak, KNN yöntemi kullanılarak önerilen sistemin performansı test edilmiştir. Şekil 2’de, önerilen yaklaşımın genel akış şeması gösterilmiştir.



Şekil 2. Önerilen sistemin genel gösterimi

IV. BENZETİM SONUÇLARI

Deneysel çalışmalar MATLAB programı kullanılarak gerçekleştirilmiştir. Bu çalışmalarda, i7 işlemci, GTX 950M 8GB GPU kartı ve 16GB RAM özelliklerine sahip bilgisayar kullanılmıştır.

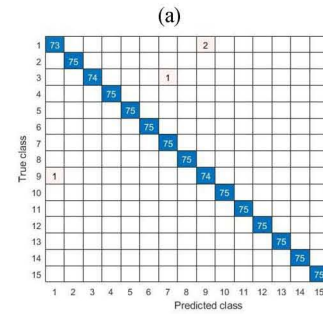
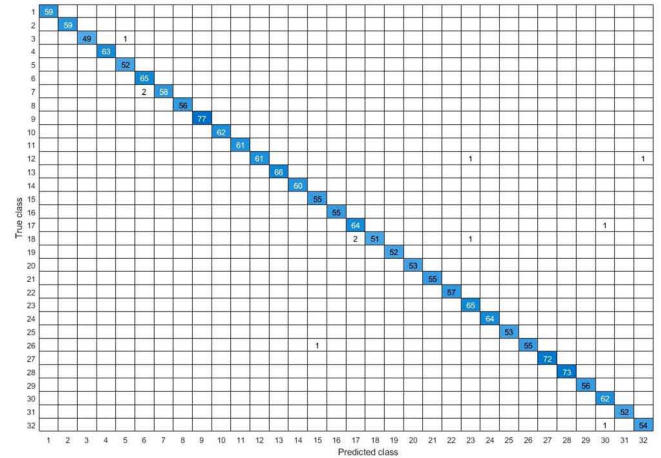
Önerilen sistemi test etmek için yaprak tabanlı bitki türleri görüntülerini içeren Flavia ve Swedish veri setleri kullanılmıştır. Önceden eğitilmiş derin mimarileri kullanarak her bir veri seti için derin özellikler çıkartılmıştır. Elde edilen özellikler TBA yöntemi kullanılarak boyutları indirgenmiştir. Daha sonra, eğitim ve test verilerini ayırmak için güvenilirliği yüksek olan 10 kat çaprazlama yöntemi kullanılmıştır. Son olarak, KNN yöntemi kullanılarak sınıflandırma performansları hesaplanmıştır. Tablo 3’de, derin mimarilerin bireysel ve hibrit performansları ile öznelilik sayıları ve önerilen sistemin performansı verilmiştir.

TABLE III. ÖNERİLEN SİSTEMİN PERFORMANS SONUÇLARI VE ÖZNETELİK SAYILARI

Model	Öznelilik Sayısı	Flavia	Swedish
AlexNet	4096	%99.1	%98.8
VGG16	4096	%98.7	%99.2
Alexnet+VGG16	8192	%99.27	%99.38
Önerilen Sistem	-	%99.42	%99.64

Tablo 3’de görüleceği üzere, önerilen sistem kullanılarak Flavia ve Swedish veri setleri için sırasıyla %99.42 ve %99.64 doğruluk elde edilmiştir. Önerilen sistem ile özelliklerin indirgenmesi için TBA yöntemi kullanılmış ve Flavia ve Swedish veri setleri için sırasıyla 52 ve 46 öznelilik sayısında en yüksek performanslar elde edilmiştir. Bu sonuçlara göre, önerilen sistem, daha az sayıda öznelilik kullanılarak daha yüksek performans sağlamıştır. Ayrıca derin mimarilerin bireysel performanslarına göre, Flavia veri seti için Alexnet modeli kullanılarak %99.1 doğruluk elde ederken, Swedish veri seti için ise VGG16 modeli kullanılarak %99.2 doğruluk elde edilmiştir. TBA özellik indirgeme yöntemi uygulanmaksızın AlexNet ile VGG16 modellerinden elde edilen derin özellikler birleştirilerek Flavia ve Swedish veri setleri için sırasıyla %99.27 ve %99.38 doğruluk elde edilmiştir.

Önerilen sistemin Flavia ve Swedish veri setleri için karmaşıklık matrisleri Şekil 3’de verilmiştir.



(b)

Şekil 3. Karmaşıklık matrisleri a) Flavia Veri seti b) Swedish Veri Seti

Bu çalışmada kullanılan Flavia ve Swedish veri setleri ile ilgili literatürde birçok çalışma yapılmıştır. En yüksek

performanslara sahip çalışmalar ile önerilen sistem karşılaştırılmış ve Tablo 4-5’de verilmiştir.

TABLE IV. FLAVIA VERİ SETİ KULLANILARAK VAR OLAN YÖNTEMLER İLE ÖNERİLEN SİSTEMİN KARŞILAŞTIRILMASI

Referanslar	Yöntem	Sınıflandırıcı	Doğruluk
[22]	Morfolojik özellikler ve Fourier Tanımlayıcılar	YSA	%96
[23]	Değiştirilmiş YİÖ	DVM	%97.6
[24]	Şekil özellikleri	KNN	%98.75
[25]	Geliştirilmiş YİÖ	Aşırı Öğrenme Makinesi (ELM)	%98.94
[26]	VGG16	Doğrusal Diskriminant Analizi (LDA)	%99.1
[27]	Derin ESA	Çok Katmanlı Algılayıcı (MLP)	%99.4
Önerilen Sistem	(Alexnet+VGG16)+TBA	KNN	%99.42

TABLE V. SWEDISH VERİ SETİ KULLANILARAK VAR OLAN YÖNTEMLER İLE ÖNERİLEN SİSTEMİN KARŞILAŞTIRILMASI

Referanslar	Yöntem	Sınıflandırıcı	Doğruluk
[28]	Şekil özelliklerine dayalı geliştirilen MARCH yöntemi	KNN	%97.33
[29]	Zernike Moment ve Yönlendirilmiş Gradyanların Histogramı (HOG)	DVM	%98.13
[30]	Şekil özelliklerine dayalı geliştirilen yöntemlerin kombinasyonu	KNN	%99.18
[26]	VGG16	ESA	%99.11
[31]	Geliştirilmiş şekil tabanlı YİÖ	KNN	%99.25
[32]	Döndürmeye karşı değişmeyen Eş-Oluşum tabanlı YİÖ	DVM	%99.38
[25]	Geliştirilmiş YİÖ	ELM	%99.46
Önerilen Sistem	(Alexnet+VGG16)+TBA	KNN	%99.64

Tablo 4-5’de, Flavia ve Swedish veri seti kullanılarak en yüksek performansa sahip çalışmalar verilmiştir. [22-25,28-32] nolu çalışmalarda geleneksel yöntemler kullanırken, [26-27] nolu çalışmalarda ise derin öğrenmeye dayalı modeller kullanılmıştır. Tablo 4-5’den anlaşılacağı üzere, önerilen sistemin önceki yapılan çalışmalara göre üstün performans sağladığı tespit edilmiştir.

Önerilen sistemin avantajları aşağıda verilmiştir. Bunlar;

- Derin mimarilerin kombinasyonu, bireysel modellere ve geleneksel yöntemlere göre daha üstün performans sağlamıştır.
- Farklı mimarilerin kombinasyonlarına dayalı geliştirilen sistem, bitki sınıflandırılmasında olumlu etkileri olduğu kanıtlanmıştır.
- TBA özellik indirgeme yöntemi kullanılarak derin özelliklerden en iyi ayırt edici özellikler çıkartılmış ve böylelikle daha az sayıda öznetelik kullanılarak daha yüksek performans sağlanmıştır.

- Önerilen sistem basit ve farklı veri setleri için uygulanabilir.

V. TARTIŞMA VE SONUÇLAR

Bu çalışmada, bitki türlerinin sınıflandırılması için önceden eğitilmiş derin öğrenme mimarilerinin kombinasyonuna dayalı bir yaklaşım önerilmiştir. ESA’ya dayalı geliştirilen AlexNet ve VGG16 modellerinin fc6 katmanını kullanarak bitki yaprak görüntülerinden derin özellikler çıkartılmıştır. Daha sonra, TBA yöntemi ile bu derin özelliklerin boyutu azaltılarak en iyi ayırt edici özellikler elde edilmiştir. Önerilen sistemi test etmek için KNN sınıflandırıcısı kullanılmıştır. Sonuç olarak, önerilen sistem kullanılarak Flavia ve Swedish veri setleri için sırasıyla %99.42 ve %99.64 doğruluk elde edilmiştir. Önerilen sistem, aynı veri setleri kullanılarak yapılan ve en yüksek performanslara sahip çalışmalar ile karşılaştırılmış ve diğer çalışmalara göre daha yüksek performansa sahip olduğu gözlenmiştir.

REFERENCES

- [1] M. Turkoglu, and D. Hanbay, “Classification of the grape varieties based on leaf recognition by using SVM classifier,” In Signal Processing and Communications Applications Conference (SIU), 2015 23th. IEEE, (2015) 2674-2677.
- [2] Z. Wang, X. Sun, Y. Ma, H. Zhang, Y. Ma, W. Xie, and Y. Zhang, “Plant recognition based on intersecting cortical model,” In Neural Networks (IJCNN), 2014 International Joint Conference on. IEEE, (2014) 975-980.
- [3] M. Turkoglu, and D. Hanbay, “Recognition of plant leaves: An approach with hybrid features produced by dividing leaf images into two and four parts,” Applied Mathematics and Computation, 352, 1-14, 2019.
- [4] F. Ahmed, A.H. Bari, A.S.M. Shihavuddin, H.A. Al-Mamun, and P. Kwan, “A study on local binary pattern for automated weed classification using template matching and support vector machine,” in: 2011 IEEE 12th International Symposium on Computational Intelligence and Informatics, CINTI, 2011, pp. 329-334.
- [5] I. El Massi, Y. Es-Saady, M. El Yassa, D. Mammass, and A. Benazoun, “Automatic recognition of the damages and symptoms on plant leaves using parallel combination of two classifiers,” In 2016 13th International Conference on Computer Graphics, Imaging and Visualization (CGiV), pp. 131-136, 2016.
- [6] K. Mahdikhani, and H. Ebrahimnezhad, “Plant leaf classification using centroid distance and axis of least inertia method,” In 2014 22nd Iranian conference on electrical engineering (ICEE), pp. 1690-1694, 2014.
- [7] A. Yasar, I. Saritas, M. A. Sahman, and A. O. Dunder, “Classification of Leaf Type Using Artificial Neural Networks,” International Journal of Intelligent Systems and Applications in Engineering 3.4, 136-139, 2015.
- [8] A. Kadir, L. E. Nugroho, A. Susanto, and P. I. Santosa, “Experiments of Zernike moments for leaf identification,” Journal of Theoretical and Applied Information Technology (JATIT) 41.1: 82-93, 2012.
- [9] M. M. Ghazi, B. Yanikoglu, and E. Aptoula, “Plant identification using deep neural networks via optimization of transfer learning parameters,” Neurocomputing, 235: 228-235, 2017.

- [10] S. Prasad, and P. P. Singh, "Medicinal plant leaf information extraction using deep features," In Region 10 Conference, TENCON 2017-IEEE, pp. 2722-2726, 2017.
- [11] P. Pawara, E. Okafor, O. Surinta, L. Schomaker, and M. Wiering, "Comparing Local Descriptors and Bags of Visual Words to Deep Convolutional Neural Networks for Plant Recognition," In: ICPRAM, pp. 479-486, 2017.
- [12] M. A. Kizrak, and B. Bolat, "Derin Öğrenme ile Kalabalık Analizi Üzerine Detaylı Bir Araştırma," Bilişim Teknolojileri Dergisi, 11(3): 263-286, 2018
- [13] M. Turkoglu, and D. Hanbay, "Apricot Disease Identification based on Attributes Obtained from Deep Learning Algorithms," In 2018 International Conference on Artificial Intelligence and Data Processing (IDAP), Malatya, Turkey, pp. 1-4, 2018.
- [14] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," In Advances in neural information processing systems, pp. 1097-1105, 2012.
- [15] K. Simonyan, and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," Computing Research Repository (CoRR), arXiv preprint arXiv:1409.1556, 2014.
- [16] E. Yildiz, Y. Sevim, "Comparison of linear dimensionality reduction methods on classification methods," Electrical, Electronics and Biomedical Engineering (ELECO), 2016 National Conference on. IEEE, 2016.
- [17] M. Karabatak, M. C. Ince, and E. Avci, "An expert system for diagnosis breast cancer based on Principal Component Analysis method," Signal Processing, Communication and Applications Conference, SIU 2008. IEEE 16th. IEEE, 2008.
- [18] A. Şengür, B. N. Akılotu, S. A. Tuncer, Z. Kadiroğlu, S. Yavuzkılıç, Ü. Budak, ve E. Deniz, "Derin Öznitelikler ile Retinal Görüntülerde Optik Diskin Belirlenmesi," Conference: 26th Signal Processing and Communications Applications Conference (SIU), 2018.
- [19] M. Turkoglu, and D. Hanbay, "Plant disease and pest detection using deep learning-based features," Turkish Journal of Electrical Engineering & Computer Sciences, 27(3), 1636-1651, 2019.
- [20] S. G. Wu, F. S. Bao, E. Y. Xu, Y. X. Wang, Y. F. Chang, and Q. L. Xiang, "A leaf recognition algorithm for plant classification using probabilistic neural network," Signal Processing and Information Technology, 2007 IEEE International Symposium on. IEEE, 2007.
- [21] O. Söderkvist, "Computer vision classification of leaves from swedish trees," 2001.
- [22] A. Aakif, and M. F. Khan, "Automatic classification of plants based on their leaves," Biosystems Engineering, 139, 66-75, 2015.
- [23] Y. G. Nareesh, and H. S. Nagendraswamy, "Classification of medicinal plants: An approach using modified LBP with symbolic representation," Neurocomputing, 173, 1789-1797, 2016.
- [24] G. Saleem, M. Akhtar, N. Ahmed, and W. S. Qureshi, "Automated analysis of visual leaf shape features for plant classification," Computers and Electronics in Agriculture, 157, 270-280, 2019.
- [25] M. Turkoglu, and D. Hanbay, "Leaf-based plant species recognition based on improved local binary pattern and extreme learning machine," Physica A: Statistical Mechanics and its Applications, 121297, 2019.
- [26] A. Kaya, A. S. Keceli, C. Catal, H. Y. Yalic, H. Temucin, and B. Tekinerdogan, "Analysis of transfer learning for deep neural network based plant classification models," Computers and Electronics in Agriculture, 158, 20-29, 2019.
- [27] S. H. Lee, C. S. Chan, S. J. Mayo, and P. Remagnino, "How deep learning extracts and learns leaf features for plant classification," Pattern Recognition, 71, 1-13, 2017.
- [28] B. Wang, D. Brown, Y. Gao, and J. La Salle, "MARCH: Multiscale-arch-height description for mobile retrieval of leaf images," Information Sciences, 302, 132-148, 2015.
- [29] D. G. Tsolakidis, D. I. Kosmopoulos, and G. Papadourakis, "Plant leaf recognition using Zernike moments and histogram of oriented gradients," Hellenic Conference on Artificial Intelligence. Springer, Cham, 2014.
- [30] H. Laga, S. Kurttek, A. Srivastava, and S. J. Miklavcic, "Landmark-free statistical analysis of the shape of plant leaves," Journal of theoretical biology, 363, 41-52, 2014.
- [31] X. Wang, J. Liang, and F. Guo, "Feature extraction algorithm based on dual-scale decomposition and local binary descriptors for plant leaf recognition," Digital Signal Processing 34, 101-107, 2014.
- [32] X. Qi, R. Xiao, C. G. Li, Y. Qiao, J. Guo, and X. Tang, "Pairwise rotation invariant co-occurrence local binary pattern," IEEE transactions on pattern analysis and machine intelligence 36.11, 2199-2213, 2014.